

Calidad de datos y análisis exploratorio de la productividad en equipos de confección

Diego Enrique Arguera canjura
Luis Fernando Figueroa puente
Erick Alexander Sánchez Miranda
José Geovani Sigüenza Sarco
Sebastián Alejandro Solano Menjívar

Universidad Evangélica de El Salvador · Ingeniería en Desarrollo de Software

Asignatura: Data Analysis

Abstract—La calidad de los registros operativos condiciona la interpretación de la productividad industrial. Este estudio analiza 1,197 observaciones y 15 variables mediante perfilado, correlaciones, detección de atípicos, codificación categórica y comparación de escaladores. Se identificaron 506 faltantes de trabajo en proceso, concentrados en acabado, y 22, 1 y 11 atípicos en trabajo en proceso, tiempo extra e incentivos, respectivamente. Se unificaron categorías y se aplicó escalado robusto, conservando las observaciones y las ausencias para evitar alteraciones sin sustento. La productividad objetivo mostró la mayor asociación positiva con la productividad real: 0.422 en Pearson y 0.448 en Spearman. El procesamiento produjo 20 columnas y preservó la asimetría y curtosis. Persisten discrepancias semánticas y valores fuera del rango documentado; por ello, el resultado es una base exploratoria trazable, cuya utilización predictiva requiere validaciones adicionales.

Index Terms—Calidad de datos, análisis exploratorio, productividad laboral, valores faltantes, escalado robusto.

I. INTRODUCCIÓN

La evaluación de equipos de confección exige interpretar conjuntamente metas, recursos e incidencias de producción. Una comparación basada únicamente en promedios puede ocultar diferencias de registro entre departamentos. Por esta razón, la preparación de datos constituye una etapa necesaria para construir indicadores operativos interpretables.

Se estudia el conjunto público Productivity Prediction of Garment Employees, alojado en UCI [1]. El objetivo es caracterizar sus problemas de calidad, documentar las transformaciones aplicadas y evaluar sus consecuencias estadísticas. El alcance es descriptivo: no se entrenan modelos ni se atribuyen efectos causales a las variables.

El análisis se organiza alrededor de tres preguntas: ¿qué variables operativas presentan mayor asociación con la productividad real?, ¿qué diferencias descriptivas aparecen entre departamentos?, y ¿cómo cambia la lectura de las asociaciones al comparar Pearson con Spearman? También se examina si el procesamiento modifica la forma de las distribuciones o solamente su escala.

La contribución consiste en una auditoría cuantitativa que distingue correcciones verificables de decisiones provisionales. La sección II presenta los datos y su diagnóstico; la sección III describe el procedimiento; la

sección IV reúne resultados y limitaciones; y la sección V establece conclusiones y trabajo futuro.

II. DESCRIPCIÓN DEL DATASET Y DIAGNÓSTICO INICIAL

A. Procedencia y unidad de observación

UCI describe registros recolectados manualmente y validados por expertos del sector [1]. La copia local contiene 1,197 filas y 15 columnas, correspondientes a 59 fechas entre el 1 de enero y el 11 de marzo de 2015. Cada fila identifica un equipo, departamento y fecha. Se observaron 12 equipos; la combinación fecha–departamento normalizado–equipo no presentó repeticiones en la auditoría complementaria.

Las variables originales se resumen en la Tabla I. La categoría “sweing” se conserva en el código para mantener correspondencia con el archivo; en la exposición se denomina costura. “Finishing” se denomina acabado. Las 15 columnas incluyen la productividad real que, en una aplicación predictiva futura, desempeñaría el papel de respuesta.

TABLA I. DICCIONARIO DE LAS VARIABLES ORIGINALES

Variable	Tipo / unidad	Descripción breve
date	Fecha	Fecha del registro
quarter	Ordinal*	Porción del mes
department	Nominal	Departamento
day	Nominal	Día de la semana
team	Identificador	Equipo de trabajo
targeted_productivity	Real / proporción	Meta de productividad
smv	Real / minutos	Tiempo estándar de tarea
wip	Conteo / unidades	Productos sin terminar
over_time	Entero / minutos	Tiempo extra del equipo
incentive	Entero / BDT	Incentivo económico
idle_time	Real / no precisada	Tiempo de interrupción
idle_men	Conteo / personas	Personal inactivo
no_of_style_change	Conteo	Cambios de estilo
no_of_workers	Real / personas**	Personal asignado
actual_productivity	Real / proporción	Productividad observada

Fuente: nombres del CSV y documentación [1]. * Orden adoptado en el notebook. ** Se observan fracciones; su significado operativo no está confirmado.

B. Cobertura, ausencias e inconsistencias

El archivo original contiene 691 registros de costura, 257 de “finishing ” y 249 de “finishing”. Al retirar espacios se obtienen 506 registros de acabado y dos categorías departamentales. No se detectaron duplicados exactos. La Tabla II consolida el diagnóstico; los porcentajes usan las 1,197 filas como denominador.

TABLA II. MATRIZ DIAGNÓSTICA DE CALIDAD

Componente	Resultado	Implicación
wip	506 nulos (42.27%)	Todos en acabado
Otras 14 columnas	0 nulos	Compleitud observada
department	3 → 2 categorías	257 etiquetas con espacio
quarter / day / team	5 / 6 / 12 valores	Variables de baja cardinalidad
date / wip	59 / 548 valores	wip: solo no nulos
Productividad real	37 > 1 (3.09%)	Revisar rango declarado
Personal asignado	140 fracciones (11.70%)	Aclarar unidad efectiva
Duplicados exactos	0	Sin eliminación
Clave fecha-depto.-equipo	0 repeticiones	Sin duplicación en esa clave

La ficha define quarter como una porción del mes y menciona cuatro partes [1]; el CSV contiene cinco etiquetas. Por tanto, no corresponde interpretarlo como trimestre del año. También existe una discrepancia entre el rango documentado de productividad, de 0 a 1 [1], y 37 observaciones superiores a 1. Estas inconsistencias se registran como limitaciones, sin sustituir valores mediante conjeturas.

III. METODOLOGÍA DE PREPROCESAMIENTO Y TRANSFORMACIÓN

A. Diseño del análisis y trazabilidad

El procedimiento comprende perfilado, exploración, limpieza, transformación y auditoría pre/post. El notebook utiliza pandas, NumPy, Matplotlib, seaborn, SciPy y scikit-learn; esta última biblioteca provee los escaladores comparados [2]. Se conservaron las filas y se distinguieron los datos originales, los datos con categorías depuradas y la representación codificada.

Para el manuscrito se recalcularon las cifras sobre el CSV local y se añadieron comprobaciones de unicidad de la clave operativa, rangos y concentración temporal de atípicos. Estas comprobaciones (unicidad de la clave operativa, hash SHA-256 del archivo fuente, anomalías de rango y concentración temporal de atípicos) se incorporaron como celdas dentro del propio notebook; no implican que se haya modificado su secuencia original. Los resultados se interpretan sobre la muestra disponible, sin extrapolación poblacional.

B. Exploración de distribuciones y asociaciones

Se examinaron histogramas, estimaciones de densidad, diagramas de dispersión y resúmenes numéricos. La visualización constituye una etapa del análisis de datos que

permite explorar la estructura y las relaciones presentes en los datos antes de aplicar métodos analíticos específicos [10].

$$r = \Sigma_i(x_i - \bar{x})(y_i - \bar{y}) / \sqrt{[\Sigma_i(x_i - \bar{x})^2 \Sigma_i(y_i - \bar{y})^2]} \quad (1)$$

$$\rho_s = \text{corr}(\text{rango}(x), \text{rango}(y)) \quad (2)$$

No se presentan pruebas de significancia que supongan independencia entre todas las filas. Los equipos aparecen repetidamente a lo largo del tiempo; además, las condiciones operativas pueden variar por departamento y fecha. Las diferencias entre coeficientes se tratan como evidencia exploratoria y no como demostración de causalidad ni de superioridad de una familia de modelos.

C. Decisión sobre valores faltantes

El 100% de los registros de acabado carece de wip y el 100% de los registros de costura dispone de ese valor. Esta coincidencia sugiere un patrón de registro asociado al departamento, pero no demuestra que la variable sea conceptualmente inaplicable al acabado. Se evita clasificar el mecanismo de ausencia como confirmado.

No se imputó con la media de costura, porque no existen observaciones de acabado que permitan contrastar esa transferencia. Tampoco se eliminaron las 506 filas: hacerlo excluiría por completo dicho departamento. Se conservaron los nulos para el análisis descriptivo y se explicitó que la decisión deja pendiente un tratamiento compatible con el futuro uso predictivo. El resultado no constituye una matriz universalmente apta para estimadores que requieren datos completos.

D. Detección y conservación de atípicos

La identificación de valores atípicos forma parte del preprocesamiento de datos y permite reconocer observaciones extremas que requieren evaluación antes de decidir si deben modificarse o conservarse [10]. Se aplicaron cercas de 1.5 veces el rango intercuartílico a wip, tiempo extra e incentivos, siguiendo el criterio de diagramas de caja descrito por NIST [5]. Se obtuvieron los cuartiles con interpolación lineal y se excluyeron los nulos del cálculo.

$$\text{IQR} = Q_3 - Q_1 \quad (3)$$

$$L_i = Q_1 - 1.5 \text{ IQR}; \quad L_s = Q_3 + 1.5 \text{ IQR} \quad (4)$$

Una observación se marcó si $x < L_i$ o $x > L_s$. La detección no se equiparó a un error: se mantuvieron los registros y se examinó su fecha. Esta conservación es provisional, pues no se dispone de los formularios originales para confirmar su validez. No se aplicaron winsorización, eliminación ni transformación logarítmica; por tanto, no se afirma haber mitigado estadísticamente los extremos.

E. Codificación e ingeniería de características

Se retiraron espacios en department y se aplicó One-Hot Encoding a department y day, omitiendo una categoría de referencia por variable. Esta operación genera $k-1$ indicadores y evita la dependencia exacta asociada a incluir todas las categorías junto con un intercepto [6]. No elimina otras posibles dependencias entre atributos.

quarter se mapeó de Quarter1–Quarter5 a los enteros 1–5; date se convirtió a fecha y se derivó month. El mes permite agrupar las 542 observaciones de enero, 443 de febrero y 212 de marzo, aunque la cobertura de marzo es parcial. La codificación de quarter conserva un orden, pero no demuestra que las distancias operativas entre sus niveles sean equivalentes.

F. Comparación y elección de escalador

Se comparó StandardScaler, basado en media y desviación poblacional [7], con RobustScaler, basado en mediana e IQR [8]. Las expresiones utilizadas son:

$$z_i = (x_i - \mu) / \sigma; \quad \sigma^2 = \Sigma_i(x_i - \mu)^2 / n \quad (5)$$

$$x_i^* = (x_i - \text{mediana}(x)) / \text{IQR}(x) \quad (6)$$

Se eligió la escala robusta por la elevada asimetría de incentivos y por conservar los extremos. Esta decisión estabiliza la referencia del centro de la distribución, pero no acota los valores ni garantiza mejor desempeño predictivo. La ecuación (6) presupone IQR positivo; en las variables con IQR cero, las salidas guardadas muestran que no se obtiene esa normalización.

El notebook aplica el escalado a diez columnas, incluyendo team y actual_productivity, y excluye wip. La auditoría reproduce esa elección; sin embargo, team es un identificador y la productividad real debe separarse de los predictores en un modelo futuro. La exclusión de wip obedece aquí a mantener la implementación existente: el porcentaje de faltantes, por sí solo, no demuestra que escalar los valores observados distorsione sus estadísticos.

G. Auditoría y prevención de fuga de datos

Se compararon media, desviación muestral, asimetría y exceso de curtosis antes y después. La desviación muestral usa $n-1$, a diferencia de la desviación poblacional de StandardScaler. La asimetría y la curtosis se calcularon con corrección por tamaño muestral; una curtosis de referencia cero corresponde a la definición de exceso de Fisher.

El escalado global del notebook se interpreta exclusivamente como exploración de esta muestra. No se reportan métricas de generalización. Para una evaluación predictiva, los datos deben dividirse antes de estimar imputaciones, escalas o decisiones de selección; el ajuste se realizaría solo con entrenamiento y se aplicaría después a validación [9]. Por la estructura temporal, se recomienda conservar fechas completas en cada partición y evaluar la repetición de equipos.

IV. RESULTADOS EXPERIMENTALES Y DISCUSIÓN

A. Productividad y diferencias departamentales

La productividad real presentó media 0.7351, mediana 0.7733 y desviación muestral 0.1745. El mínimo fue 0.2337 y el máximo 1.1204. La media inferior a la mediana y la asimetría de -0.8075 indican una cola más extendida hacia valores bajos; los registros mayores que 1 se conservaron como discrepancia pendiente de explicación.

TABLA III. PRODUCTIVIDAD POR DEPARTAMENTO

Departamento	n	Media	Desv.
Acabado	506	0.7530	0.1970
Costura	691	0.7220	0.1548

Acabado superó a costura en 0.0309 unidades de productividad, equivalentes a 3.09 puntos porcentuales si se interpreta la escala como proporción. Esta diferencia es descriptiva y no controla metas, fechas ni composición de equipos. Los departamentos también difieren en tamaño medio del equipo (10.25 frente a 52.45 trabajadores) y tiempo extra medio (1,917.15 frente a 6,508.21 minutos). En consecuencia, no se identifica un efecto departamental aislado.

B. Asociaciones con la productividad real

TABLA IV. ASOCIACIÓN CON LA PRODUCTIVIDAD REAL

Variable	n	Pearson	Spearman
Meta	1197	0.422	0.448
Trabajo en proceso	691	0.131	0.233
Incentivo	1197	0.077	0.217
Tiempo extra	1197	-0.054	-0.076
Personal asignado	1197	-0.058	-0.035
Tiempo inactivo	1197	-0.081	-0.148
Personal inactivo	1197	-0.182	-0.148
Cambios de estilo	1197	-0.207	-0.266
Tiempo estándar	1197	-0.122	-0.122

La meta de productividad presentó la mayor asociación positiva entre las variables numéricas analizadas: $r = 0.422$ y $\rho_s = 0.448$. Entre las variables operativas destacaron los cambios de estilo por su asociación negativa ($r = -0.207$; $\rho_s = -0.266$). Tiempo extra y personal asignado mostraron coeficientes próximos a cero; esto no descarta relaciones condicionadas por departamento o patrones que los coeficientes no describan adecuadamente.

wip e incentive presentaron asociaciones mayores en rangos que en valores originales. No obstante, los coeficientes de Spearman permanecieron en magnitudes modestas (0.233 y 0.217). La discrepancia puede motivar análisis estratificados y de sensibilidad; por sí sola no demuestra una función no lineal específica. La asociación de wip se refiere únicamente a costura y no puede generalizarse al acabado.

C. Atípicos y concentración temporal

TABLA V. ATÍPICOS SEGÚN EL CRITERIO IQR

Variable	Límite inf.	Límite sup.	n (%)
wip	57.5	1,969.5	22 (3.18)
over_time	-6,840	15,240	1 (0.08)
incentive	-75	125	11 (0.92)

Denominador: 691 valores observados para wip y 1,197 para las otras variables. Los límites negativos son cercas estadísticas, no valores físicamente permitidos.

Diez de los 22 atípicos de wip ocurrieron el 2 de febrero de 2015; diez de los 11 de incentive, el 9 de marzo. La concentración sugiere revisar eventos compartidos o cambios

de registro, aunque no permite distinguir entre ambas explicaciones. El único atípico de tiempo extra fue 25,920 minutos. Como la magnitud corresponde al equipo, no debe interpretarse como duración de la jornada de una sola persona.

D. Impacto del procesamiento

La representación final contiene 1,197 filas y 20 columnas: el reemplazo de department y day por seis indicadores incrementó en cuatro el número de columnas, y month añadió una más. Se conservaron los 506 nulos de wip y todos los atípicos. El cambio comprobado de calidad fue la unificación de las etiquetas de acabado y la explicitación del formato temporal; el escalado y la codificación modificaron la representación.

TABLA VI. MEDIA Y DESVIACIÓN ANTES/DESPUÉS

Variable	μ antes	s antes	μ después	s después
Tiempo extra	4567.460	3348.824	0.110	0.607
Incentivo	38.211	160.183	0.764	3.204
T. inactivo	0.730	12.710	0.730	12.710
Productividad	0.735	0.174	-0.191	0.873
wip*	1190.466	1837.455	1190.466	1837.455

s: desviación muestral. * wip no se escaló. Los valores posteriores escalados son adimensionales.

TABLA VII. FORMA DE LA DISTRIBUCIÓN PRE/POST

Variable	Asimetría antes / después	Curtosis antes / después
Tiempo extra	0.673 / 0.673	0.424 / 0.424
Incentivo	15.791 / 15.791	299.032 / 299.032
T. inactivo	20.545 / 20.545	442.638 / 442.638
Productividad	-0.807 / -0.807	0.333 / 0.333

La igualdad de asimetría y curtosis en la Tabla VII es coherente con una transformación afín creciente. Cambian la ubicación y la unidad, pero se conserva la forma. En particular, incentive mantiene asimetría 15.791 y exceso de curtosis 299.032. Una reducción de la magnitud numérica no constituye evidencia de eliminación de ruido ni de normalidad.




Fig. 1. Distribución pre/post del tiempo extra. Los 12 intervalos se corresponden mediante la transformación robusta; las frecuencias permanecen iguales.

La Fig. 1 muestra la correspondencia entre las distribuciones original y transformada. Los intervalos se trasladaron con la misma función para evitar atribuir al escalador diferencias producidas por elegir otras divisiones del histograma. Todos los registros, incluido el extremo superior, permanecen representados.

TABLA VIII. MATRIZ DE PEARSON PRE/POST

	M	H	I	C	P
M	1.00	-0.09	0.03	-0.21	0.42
H	-0.09	1.00	-0.00	0.06	-0.05
I	0.03	-0.00	1.00	-0.03	0.08
C	-0.21	0.06	-0.03	1.00	-0.21
P	0.42	-0.05	0.08	-0.21	1.00

M: meta; H: tiempo extra; I: incentivo; C: cambios de estilo; P: productividad. $n = 1,197$. La matriz es la misma antes y después del escalado, dentro de la precisión numérica.

La matriz de la Tabla VIII se conserva porque el escalado aplicado a estas columnas es afín con divisor positivo. También se conservan los rangos y, por tanto, los coeficientes de Spearman. No se presenta la invariancia de correlaciones como una mejora de las relaciones, sino como una propiedad verificable del procesamiento.

E. Limitaciones y reproducibilidad

La ausencia de wip, el significado de los trabajadores fraccionarios y la productividad superior a 1 siguen sin confirmación operativa. La conservación de extremos mantiene información potencialmente relevante, pero también puede preservar errores. No se realizó una comparación

experimental de políticas de imputación o mitigación; por ello, no se declara una solución óptima de limpieza.

En `idle_time`, `idle_men` y `no_of_style_change` los cuartiles primero y tercero son cero. Las salidas del notebook muestran que esas columnas conservan su escala numérica. El resultado advierte que el escalado robusto no iguala automáticamente la dispersión de todas las variables, especialmente en distribuciones con fuerte concentración en cero.

El notebook registra Python 3.11.9 y fija pandas 2.2.3, NumPy 2.1.3, Matplotlib 3.10.0, seaborn 0.13.2, scikit-learn 1.6.1 y SciPy 1.16.3. La auditoría del manuscrito se ejecutó por separado con NumPy y SciPy sobre el archivo local y contrastó las cifras con las salidas guardadas. El notebook se ejecutó de forma integral en el entorno declarado, de principio a fin y sin errores, y sus salidas coinciden con las cifras reportadas en el manuscrito.

La carga se fijó al commit `2d011cc1f0f1cd23e9476221cbb8d6ac71b72126` del repositorio de GitHub (en vez de la rama modificable `main`), lo que garantiza que el CSV no cambie entre ejecuciones. La copia local usada para la auditoría del manuscrito conserva la misma huella SHA-256, incluida en la evidencia adjunta. El notebook contiene la exportación de `garments_worker_productivity_clean.csv`; debe comprobarse su generación junto con la ejecución final. Estos puntos son condiciones de entrega y no resultados experimentales ya demostrados.

V. CONCLUSIONES Y TRABAJO FUTURO

El perfilado identificó una ausencia concentrada por departamento, inconsistencias textuales y extremos agrupados temporalmente. La corrección de espacios recuperó dos departamentos y el procesamiento conservó 1,197 observaciones, con una representación final de 20 columnas. La completitud de `wip` no mejoró, porque se decidió mantener sus 506 ausencias hasta disponer de sustento para tratarlas.

La productividad objetivo mostró la asociación positiva más alta con la productividad real. Entre los factores operativos, los cambios de estilo presentaron una asociación negativa mayor que tiempo extra o personal asignado en magnitud absoluta. Acabado registró una media superior a costura, aunque la comparación no controla diferencias de operación ni dependencia temporal. Las respuestas a las preguntas iniciales son, por tanto, descriptivas y específicas de la muestra.

El escalado robusto modificó ubicación y escala sin alterar asimetría, curtosis ni correlaciones. Su utilidad en este trabajo es representar las variables respecto de su centro y dispersión intercuartílica; no equivale a eliminar anomalías. La comparación entre Pearson y Spearman amplió la exploración de `wip` e `incentive`, pero no justificó afirmaciones causales ni ventajas predictivas de modelos no evaluados.

Como continuación, se requiere validar las discrepancias con documentación operativa, evaluar los extremos por fecha y departamento y formalizar la estrategia de `wip` para acabado.

También conviene revisar la representación de `team`, separar la respuesta y analizar indicadores por trabajador cuando su definición sea defendible. Cualquier modelado deberá ajustar transformaciones solo en entrenamiento y evaluar con particiones acordes con el tiempo y los equipos.

REFERENCIAS

- [1] “Productivity Prediction of Garment Employees,” UCI Machine Learning Repository, conjunto de datos, 2020, doi: 10.24432/C51S6D. [En línea]. Disponible: <https://doi.org/10.24432/C51S6D>
- [2] F. Pedregosa et al., “Scikit-learn: Machine Learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [En línea]. Disponible: <https://jmlr.org/papers/v12/pedregosa11a.html>
- [3] SciPy Developers, “`pearsonr`,” SciPy API Reference. Consultado: 21 sep. 2026. [En línea]. Disponible: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.pearsonr.html>
- [4] SciPy Developers, “`spearmanr`,” SciPy API Reference. Consultado: 21 sep. 2026. [En línea]. Disponible: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.spearmanr.html>
- [5] NIST/SEMATECH, “Box Plot,” e-Handbook of Statistical Methods, sec. 1.3.3.7. Consultado: 21 sep. 2026. [En línea]. Disponible: <https://www.itl.nist.gov/div898/handbook/eda/section3/boxplot.htm>
- [6] The pandas Development Team, “`pandas.get_dummies`,” pandas 2.2.3 documentation. Consultado: 21 sep. 2026. [En línea]. Disponible: https://pandas.pydata.org/pandas-docs/version/2.2/reference/api/pandas.get_dummies.html
- [7] Scikit-learn Developers, “`StandardScaler`,” scikit-learn 1.6.1 documentation. Consultado: 21 sep. 2026. [En línea]. Disponible: <https://scikit-learn.org/1.6/modules/generated/sklearn.preprocessing.StandardScaler.html>
- [8] Scikit-learn Developers, “`RobustScaler`,” scikit-learn 1.6.1 documentation. Consultado: 21 sep. 2026. [En línea]. Disponible: <https://scikit-learn.org/1.6/modules/generated/sklearn.preprocessing.RobustScaler.html>
- [9] Scikit-learn Developers, “Common pitfalls and recommended practices,” scikit-learn 1.6.1 documentation. Consultado: 21 sep. 2026. [En línea]. Disponible: https://scikit-learn.org/1.6/common_pitfalls.html
- [10] T. A. Runkler, *Data Analytics: Models and Algorithms for Intelligent Data Analysis*, 1st ed. Wiesbaden, Germany: Vieweg+Teubner Verlag, 2012, doi: 10.1007/978-3-8348-2589-6. (Fuente consultada en biblioteca UEES)